



PUC Minas

Leonardo Vieira Machado

Nicolas Almeida Prado da Silva

Caracterizando a atividade de code review no github

Belo Horizonte 2026



PUC Minas

Sumário

1. Introdução	2
2. Metodologia	4
2.1 Passo a passo do experimento	5
2.2 Decisões	5
2.3 Materiais utilizados	5
2.4 Métodos utilizados	6
2.5 Métricas e suas unidades	6
3. Visualização dos Resultados	6
3.1 Visualização tabular e gráfica dos dados colhidos	6
4.1 Confronto das Questões de Pesquisa	14
4.2 Insights e Estatísticas	15
5. Conclusão	15
5.1 Tomada de Decisão	15
5.2 Sugestões Futuras	15

1. Introdução

1.1 Contextualização

No contexto do desenvolvimento ágil e de sistemas *open source*, a revisão de código consolidou-se como uma prática fundamental para inspecionar e garantir a qualidade do software. Em plataformas como o GitHub, essa dinâmica ocorre através de *Pull Requests*, que funcionam como fóruns de avaliação antes da integração. Compreender as variáveis que influenciam a aprovação (*MERGE*) ou rejeição (*CLOSE*) dessas submissões é essencial para otimizar os fluxos de trabalho da equipe de engenharia.

1.2 Problema foco no experimento

O problema central deste experimento reside na dificuldade de compreender, com base em dados empíricos, quais fatores e características de um PR influenciam diretamente na sua aceitação ou rejeição, bem como no esforço de revisão exigido pela comunidade.

1.3 Questões-Pesquisa (RQs)

Para guiar o experimento, foram definidas as seguintes Questões de Pesquisa:

A. Feedback Final das Revisões (Status do PR):

- RQ 01. Qual a relação entre o tamanho dos PRs e o feedback final das revisões?
 - Hipótese: Espera-se que PRs menores (menos arquivos e linhas) tenham maior taxa de aceitação (Merge).
- RQ 02. Qual a relação entre o tempo de análise dos PRs e o feedback final das revisões?
 - Hipótese: Espera-se que PRs com menos tempo de análise tenham menor taxa de aceitação (Merge).
- RQ 03. Qual a relação entre a descrição dos PRs e o feedback final das revisões?
 - Hipótese: Espera-se que PRs mais descritivos tenham maior taxa de aceitação.
- RQ 04. Qual a relação entre as interações nos PRs e o feedback final das revisões?
 - Hipótese: Espera-se que PRs com mais interações tenham maior taxa de aceitação.

B. Número de Revisões:

- RQ 05. Qual a relação entre o tamanho dos PRs e o número de revisões realizadas?
 - Hipótese: Espera-se que PRs menores tenham menos revisões realizadas.
- RQ 06. Qual a relação entre o tempo de análise dos PRs e o número de revisões realizadas?
 - Hipótese: Espera-se que PRs com mais tempo de análise tenham um número maior de

revisões realizadas.

- RQ 07. Qual a relação entre a descrição dos PRs e o número de revisões realizadas?
 - Hipótese: Espera-se que PRs mais descritivos, tenham menos revisões realizadas.
- RQ 08. Qual a relação entre as interações nos PRs e o número de revisões realizadas?
 - Hipótese: Espera-se que PRs mais interações, tenham mais revisões realizadas.

1.4 Objetivo


Analisar a atividade de *code review* em repositórios populares do GitHub, com o intuito de identificar quais variáveis influenciam no *merge* de um PR e na quantidade de revisões realizadas, sob a ótica dos desenvolvedores que submetem contribuições.

1.5 Objetivos específicos

- Minerar dados de PRs submetidos aos 200 repositórios mais populares do GitHub.
- Quantificar e comparar o tamanho, tempo de análise, descrição e interações dos PRs em relação ao seu feedback final (aprovado/MERGED ou rejeitado/CLOSED).
- Correlacionar essas mesmas métricas com a quantidade total de revisões recebidas por PR.
- Aplicar testes estatísticos robustos para validar as hipóteses levantadas.



2. Metodologia



2.1 Passo a passo do experimento

A coleta de dados foi realizada através da API GraphQL do GitHub. Foram selecionados 200 repositórios populares, extraíndo-se os últimos 100 PRs de cada um, totalizando 20.000 PRs. Foi realizado um filtro para garantir que os PRs analisados tenham tido no mínimo uma revisão, e que tenham também mais de uma hora de vida.

2.2 Decisões

Para a análise de correlação, utilizou-se o teste de **Spearman**. Esta escolha justifica-se pelo fato de os dados de desenvolvimento de software geralmente não seguirem uma distribuição normal, apresentando muitos *outliers* e assimetria, o que torna os testes não-paramétricos mais robustos.

2.3 Materiais utilizados

- **Linguagem de Programação:** Python.
- **Bibliotecas de Manipulação e Visualização de Dados:** pandas, numpy, matplotlib, seaborn.
- **Biblioteca de Análise Estatística:** scipy (para os testes de Mann-Whitney U e Correlação de Spearman).
- **Fonte de Dados e Integração:** API GraphQL do GitHub (consumida via biblioteca requests).

2.4 Métodos utilizados

O experimento baseou-se na técnica de Mineração de Repositórios de Software. Inicialmente, executou-se um script para consumir a API GraphQL do GitHub, filtrando PRs que passaram por revisão humana (descartando interações exclusivas de bots através do filtro de tempo mínimo de 1 hora). Para a análise de dados. Utilizou-se o teste Mann-Whitney U para avaliar a significância das diferenças entre as métricas de PRs MERGED e CLOSED (RQ 01 a 04). Para as análises de correlação com o número de revisões (RQ 05 a 08), aplicou-se o teste de Correlação de Spearman. A visualização de dados focou no uso de *boxplots* (com e sem remoção de *outliers* pelo método IQR) e gráficos de dispersão.

2.5 Métricas e suas unidades

<u>Métrica</u>	<u>Descrição</u>	<u>Obtenção</u>
Status	Status do PR(Merged/Closed)	pr.get("state", "UNKNOWN")
Tamanho_Arquivos	Arquivos modificados no PR	pr.get("changedFiles", 0)
Tamanho_Linhas_Adicionadas	Linhas adicionadas no PR	pr.get("additions", 0)
Tamanho_Linhas_Removidas	Linhas removidas no PR	pr.get("deletions", 0)
Tempo_Analise_Horas	Horas entre a criação do PR até sua resposta de Merge ou Close	round(duration_hours, 2)
Descrica_Caracteres	Quantidade de caracteres na descrição do PR	desc_length
Interacoes_Participantes	Participantes que contribuíram no PR	participants_count
Interacoes_comentarios	Participantes que comentaram em PR	comments_count
Revioes	Revisões realizadas no PR	reviews_count




PUC Minas

3. Visualização dos Resultados

3.1 Visualização tabular e gráfica dos dados colhidos

Métrica	Média	Mediana	Desvio Padrão
Tamanho (Arquivos)	17,94	2,00	287,69
Linhas Adicionadas	1190,85	22,00	36318,00
Linhas Removidas	836,86	4,00	17013,50
Tempo de Análise (h)	601,70	36,95	2560,49
Descrição (Caracteres)	1643,68	786,00	3687,15
Participantes	2,90	2,00	4,29
Comentários	2,76	1,00	8,83
Revisões	2,86	1,00	6,73



Este gráfico apresenta a força e a direção da relação entre todas as métricas coletadas.



PUC Minas

Observa-se uma correlação positiva moderada a forte entre métricas de tamanho (Arquivos Alterados e Linhas Adicionadas 0.73). As correlações com o Status (Merged) são geralmente baixas, indicando que nenhuma métrica isolada garante a aceitação do PR.


Resumo - Medianas por Status do PR

Metrica	MERGED	CLOSED
Tamanho_Arquivos	2.00	2.00
Tamanho_Linhas_Adicionadas	22.00	21.00
Tamanho_Linhas_Removidas	5.00	2.00
Tempo_Analise_Horas	27.11	100.70
Descricao_Caracteres	767.50	834.00
Interacoes_Participantes	2.00	3.00
Interacoes_Comentarios	1.00	2.00
Revisoes	1.00	1.00

Uma tabela comparativa que contrasta o "perfil típico" de um PR que foi aceito (*Merged*) versus um que foi rejeitado (*Closed*).


A diferença mais gritante está no Tempo de Análise, onde PRs fechados sem merge levam quase 4 vezes mais tempo (mediana de 100.7h) do que os aprovados (27.1h).

RQ 01 - Tamanho dos PRs vs Feedback Final (Status)





PUC Minas



Três boxplots comparando a quantidade de arquivos, linhas adicionadas e linhas removidas entre PRs aprovados e reprovados.


PRs aprovados tendem a ser ligeiramente maiores em termos de arquivos alterados (Md=2.0 vs Md=1.0) e linhas removidas, com significância estatística ($p < 0.001$).



PUC Minas

RQ 02 - Tempo de Analise (horas) vs Feedback Final (Status)

Mann-Whitney: *** (p < 0.001)






PUC Minas

RQ 02 (Sem Outliers) - Tempo de Analise (horas) vs Feedback Final (Status)

Mann-Whitney: *** ($p < 0.001$) [N_merged=12931, N_closed=4330]




Boxplot que analisa o impacto do tempo decorrido até a decisão final do PR.

Existe uma diferença estatisticamente significativa ($p < 0.001$) que mostra que PRs reprovados (*Closed*) costumam ficar abertos por muito mais tempo ($Md=53.3h$) do que os aprovados ($Md=20.6h$).



PUC Minas




Boxplot comparando a quantidade de caracteres na descrição do PR entre os dois grupos de status.

O teste de Mann-Whitney resultou em um $p = 0.0573$ (não significativo ao nível de 5%), sugerindo que o tamanho da descrição não é um fator determinante para o sucesso do merge nesta amostra.




PUC Minas



Dois boxplots analisando o número de participantes e o número de comentários em relação ao desfecho do PR.

PRs reprovados tendem a ter mais participantes e mais comentários (Md=3.0 e Md=2.0, respectivamente) do que os aprovados, possivelmente indicando debates mais longos em contribuições problemáticas.



Gráficos de dispersão com linhas de tendência relacionando métricas de tamanho ao esforço de revisão.

Há uma correlação positiva fraca (entre 0.18 e 0.28). À medida que o número de arquivos ou linhas aumenta, o número de revisões tende a subir, mas a dispersão é alta.



PUC Minas

RQ 06 - Tempo de Analise (horas) vs Numero de Revisoes




Gráfico de dispersão relacionando o tempo que o PR ficou aberto com a quantidade de revisões recebidas.

A correlação é quase nula, 0.099, indicando que um PR ficar muito tempo aberto não significa necessariamente que ele está passando por múltiplas revisões técnicas.



PUC Minas

RQ 07 - Tamanho da Descrição (chars) vs Numero de Revisoes





Gráfico de dispersão analisando se descrições mais longas resultam em mais ou menos revisões.

Correlação positiva muito baixa, 0.143, sugerindo que detalhar mais a descrição tem pouco impacto direto na quantidade de ciclos de revisão.



PUC Minas



Gráficos de dispersão relacionando o engajamento (comentários e participantes) com o número de revisões.

Esta é uma das correlações mais fortes entre as métricas de processo, 0.321 para participantes, sugerindo que quanto mais pessoas se envolvem na discussão, maior tende a ser o número de revisões formais.

4.1 Confronto das Questões de Pesquisa

Nesta seção, os resultados obtidos através das medianas e dos testes estatísticos são confrontados com as hipóteses iniciais, respondendo individualmente a cada questão de pesquisa formulada.

Dimensão A: Feedback Final das Revisões (Status do PR)

- **RQ 01. Qual a relação entre o tamanho dos PRs e o feedback final das revisões?**
 - **Resultado:** Embora o teste de Mann-Whitney tenha indicado uma diferença estatisticamente significativa ($p < 0,001$), a mediana foi idêntica em ambos os grupos ($Md = 2$ arquivos).
 - **Confronto:** Esperava-se que PRs menores tivessem maior taxa de aceitação. Os dados mostram que, em repositórios populares, o tamanho mediano das contribuições é mantido pequeno de forma padronizada, sugerindo que o tamanho por si só não é o único determinante para o *merge* em contribuições de baixo escopo.
- **RQ 02. Qual a relação entre o tempo de análise dos PRs e o feedback final das revisões?**
 - **Resultado:** PRs com status *Merged* possuem um tempo de análise consideravelmente menor ($Md = 20,6h$) do que os PRs *Closed* ($Md = 53,3h$).
 - **Confronto:** A hipótese de que PRs aceitos são processados mais rapidamente foi confirmada. O tempo elevado nos PRs rejeitados indica que contribuições problemáticas tendem a ficar "estagnadas" ou exigem ciclos mais longos de debate antes da decisão final de fechamento.
- **RQ 03. Qual a relação entre a descrição dos PRs e o feedback final das revisões?**
 - **Resultado:** Não foi observada uma diferença estatística relevante entre os grupos ($p =$



PUC Minas

0,0573).

- **Confronto:** Contrariando a expectativa de que descrições mais longas facilitariam o *merge*, os dados sugerem que a extensão da descrição não garante a aceitação da contribuição nestes repositórios.

- **RQ 04. Qual a relação entre as interações nos PRs e o feedback final das revisões?**

- **Resultado:** PRs rejeitados (*Closed*) apresentaram maior engajamento social (Md = 3 participantes e 2 comentários) do que os aceitos (Md = 2 participantes e 1 comentário).
- **Confronto:** O resultado confirma que PRs que enfrentam dificuldades técnicas ou conceituais geram mais discussões e envolvem mais colaboradores antes de serem descartados pela equipe mantenedora.

Dimensão B: Número de Revisões

- **RQ 05 a RQ 08. Relação das métricas com o número de revisões realizadas:**

- **Resultado:** Todas as correlações de Spearman foram positivas e significativas ($p < 0,001$). As interações (RQ 08) apresentaram a maior associação ($\rho = 0,33$ para participantes), enquanto tamanho (RQ 05) e tempo (RQ 06) mostraram influência moderada (ρ entre 0,12 e 0,28).
- **Confronto:** Conforme previsto, o esforço de revisão está mais fortemente atrelado ao componente social e comunicativo (interações) do que apenas ao volume de código alterado. Isso reforça que o *code review* é um processo de colaboração humana onde a discussão técnica dita o volume de revisões necessárias.

4.2 Insights e Estatísticas

O experimento demonstrou que a atividade de code review no GitHub é altamente influenciada pelo nível de engajamento dos participantes. Embora o tamanho do código alterado tenha impacto, a comunicação (através de comentários e descrições) e o tempo dedicado à análise são os fatores que melhor caracterizam a complexidade do processo de revisão.

5. Conclusão

5.1 Tomada de Decisão

Recomenda-se que equipes priorizem PRs pequenos e bem delimitados, reduzindo o tempo de resposta dos revisores, pois PRs que ficam abertos por mais tempo tendem a ser rejeitados. O envolvimento de múltiplos revisores eleva a qualidade do processo, mas deve ser calibrado pela complexidade do PR para não onerar a comunicação. A descrição detalhada, isoladamente, não se mostrou determinante para o aceite, reforçando que a qualidade do código e a agilidade na revisão são os fatores centrais.

5.2 Sugestões Futuras

Estudos futuros poderiam estratificar os repositórios por domínio (bibliotecas, aplicações web, ferramentas DevOps) para verificar se os padrões de revisão variam entre comunidades distintas. A incorporação de métricas qualitativas, como sentimento dos comentários e experiência dos revisores, permitiria investigar fatores humanos não capturados pelos dados estruturais. Também seria relevante aplicar um filtro mais rigoroso para excluir revisões automatizadas por bots, reduzindo ruído nas correlações e aumentando a precisão dos resultados.